Clinic Cursos: arquitetura do sistema central em produção

Documento técnico complementar ao documento de 5 páginas · 30/10/2026 · para o fundador e a banca técnica · desenho proposto, sem acesso aos sistemas da Clinic. Versões e preços foram consultados nas fontes oficiais na data indicada na seção 16; o que depende das respostas às perguntas P1 a P8 do documento principal está marcado como premissa.

Resumo

1. **O que é.** O sistema que liga rastreamento, CRM, atendimento no WhatsApp com IA e ERP, mantido por um profissional dedicado. A demo entregue no repositório é uma fatia funcional deste desenho: o mesmo núcleo, as mesmas regras e as mesmas ferramentas.
2. **Forma.** Um monólito modular em TypeScript sobre PostgreSQL. No centro, um log de eventos só de acréscimo; ao redor, módulos de identidade, origem, CRM, conversas e regras. O Chatwoot é a caixa de atendimento, trocável. O ERP continua dono de venda, pagamento, turma e vaga.
3. **Onde roda.** Na AWS em São Paulo, atrás da Cloudflare, sem nenhuma porta aberta para a internet. Começa em um servidor e passa a dois servidores e um PostgreSQL gerenciado quando as três unidades entram.
4. **Integrações.** API oficial do WhatsApp (Meta), ERP, Hotmart, RD Station durante a transição, Meta e Google para conversões e Claude API para a IA. Toda saída passa por uma caixa de saída com nova tentativa e chave contra repetição.
5. **Custo.** Infraestrutura de cerca de US$ 112 por mês no piloto e US$ 383 nas três unidades (US$ 494 com a réplica de análise), a preço de lista da AWS em São Paulo. Somam-se as mensagens do WhatsApp, cerca de R$ 1.870 por mês nas três unidades, e a IA, de US$ 10 a US$ 360 por mês conforme o modelo que passar no teste (seção 13). Nenhuma licença paga é obrigatória.
6. **Riscos maiores.** Dependência de uma pessoa, política do WhatsApp para IA e um ERP sem API. O desenho reduz os três: operação simples e documentada, IA que só ganha autonomia medida, e conciliação quando o ERP não avisa (seção 15).

A arquitetura em camadas

Canais	LP e formulários, links curtos e QR das unidades, WhatsApp, checkout da Hotmart, anúncios	site atual, Meta, Google, Hotmart
Borda	DNS, TLS, proteção contra ataques, login da equipe com SSO, túnel até os servidores	Cloudflare: DNS, proxy, WAF, Access, Tunnel
Porta de entrada	confere assinatura, valida o formato, grava antes de usar, descarta repetição	módulo gateway: Hono + Zod
Núcleo de dados	log de eventos só de acréscimo, cofre de dados pessoais cifrado, projeções refeitas do log	PostgreSQL 18
Domínio	identidade, origem e atribuição, oportunidades, conversas, regras e monitor de cobertura	módulos TypeScript no Node.js 26 LTS
Ferramentas e IA	as mesmas ferramentas para pessoas e agentes, com papel, aprovação e chave contra repetição	registro de ferramentas, Claude API, servidor MCP
Integrações	envio confiável para ERP, Chatwoot, WhatsApp, Meta, Google e RD	caixa de saída + fila pg-boss no PostgreSQL
Experiência	painel (CRM, Campanhas, Bastidores) e caixa de atendimento das unidades	React + Vite; Chatwoot com app de painel
Dados e análise	Grande Cérebro: funil, atribuição com regra e versão, investimento, vagas	réplica de leitura, Metabase, Python
Plataforma	implantação, segredos, backup, observabilidade, pipeline	AWS São Paulo, Docker, Coolify, GitHub Actions, SOPS, pgBackRest, OpenTelemetry

> **Resposta objetiva:** um núcleo próprio em TypeScript e PostgreSQL, com o log de eventos no centro, o Chatwoot como caixa de atendimento e o ERP como dono da venda, rodando em São Paulo atrás da Cloudflare e operável por uma pessoa.

---

1. Escopo, premissas e requisitos

As frentes do desafio no sistema

Frente	Onde fica	Regra de dono
ERP	integração de dois sentidos: pedido sai do núcleo, venda volta por webhook	o ERP é a fonte oficial de venda, pagamento, turma e vaga; o núcleo só reage e mostra
Rastreamento	porta de entrada, gerador de links e QR, origem e atribuição, monitor de cobertura	o núcleo é dono da origem, com nível de prova em cada campo
CRM próprio	identidade, oportunidades e painel; histórico do ERP exibido por consulta	o núcleo é dono da pessoa e da oportunidade; "ganha" só com o ERP
Atendimento próprio	WhatsApp oficial, Chatwoot, agente de IA e passagem para pessoa	o Chatwoot é dono da conversa; o núcleo é dono do envio e do registro
Agente de tráfego	leitura diária de investimento por campanha e tela Campanhas	as plataformas de anúncio são donas do investimento; mudar verba exige aprovação
Grande Cérebro	réplica de leitura, painéis e agentes com ferramentas só de leitura	cálculo oficial (vendas, saldo, comissões, DRE) fica nos sistemas responsáveis

Premissas de dimensionamento

Hipóteses até a resposta de P5 (volume por unidade e canal). O desenho folga muito acima delas; o que dita a forma é a operação por uma pessoa, não a carga.

Grandeza	Premissa	Consequência no desenho
Leads novos	10 mil/mês	cerca de 15 por hora; picos de campanha de 10 vezes cabem num processo
Mensagens de WhatsApp	80 mil/mês	entrada e saída; a Meta reenvia por até 7 dias se o núcleo cair
Eventos no log	300 mil/mês	cerca de 7 GB por ano com índices; refazer as projeções leva minutos
Conversas com IA	6 mil/mês	custo de modelo estimado na seção 13
Atendentes simultâneos	até 30	um Chatwoot com caixas por unidade
Equipe técnica	1 pessoa	um repositório, uma linguagem, um banco, poucos fornecedores

Requisitos não funcionais

Requisito	Meta	Como o desenho atende
Disponibilidade da entrada	99,5% ao mês	gravar e responder em seguida; reenvio da Meta (7 dias) e da Hotmart (5 vezes); formulário com caminho de volta ao RD
Confirmação de webhook	p95 abaixo de 1 s	a porta de entrada só valida e grava; o resto vai para a fila
Primeira resposta da IA	p95 abaixo de 20 s	fila dedicada, contexto curto em cache, ERP consultado com tempo limite
Painel	p95 abaixo de 500 ms	projeções prontas no banco, sem cálculo pesado na tela
Perda máxima de dados (RPO)	5 min no piloto; segundos na fase de 90 dias	WAL enviado sem parar ao S3; depois, banco gerenciado com réplica síncrona
Tempo de recuperação (RTO)	4 h no piloto; 1 h na fase de 90 dias	restauração ensaiada todo mês; imagem e configuração versionadas

LGPD	dado pessoal só no cofre; dado de saúde fora do marketing	cofre cifrado por pessoa; apagamento por destruição da chave (seção 9)
Operação	uma pessoa mantém	deploy de um clique, rotina diária de 15 minutos, runbooks (seção 11)

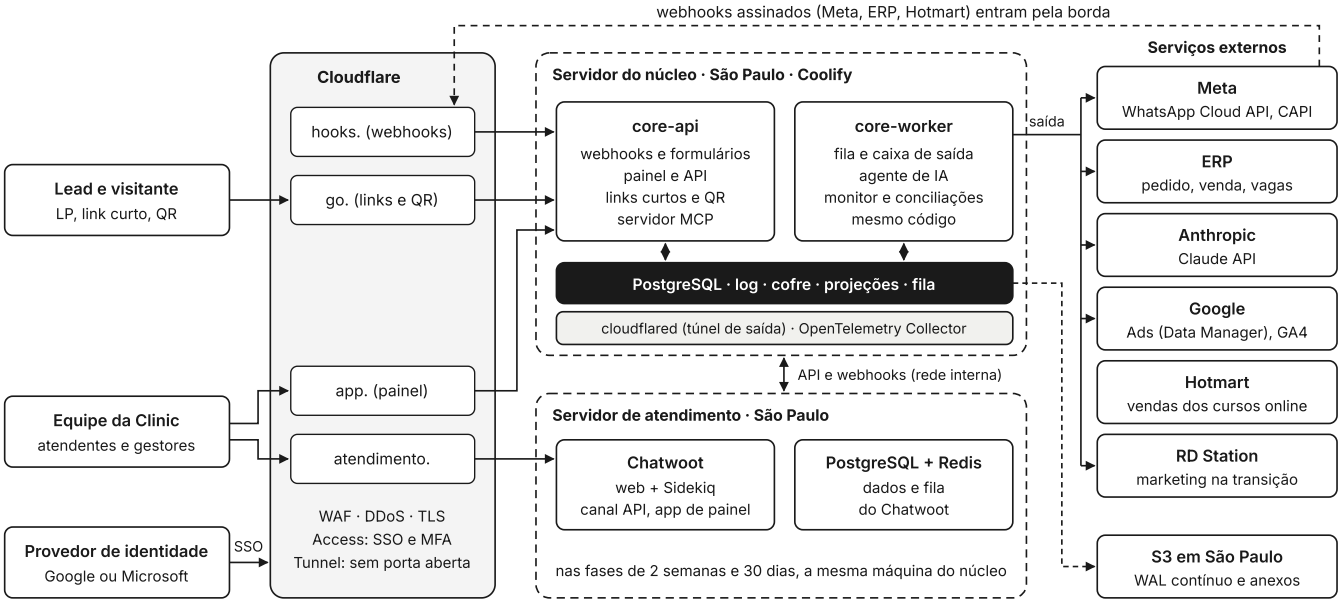
Princípios

1. **Gravar antes de usar.** Todo fato entra no log, só de acréscimo; pessoa, oportunidade e fila são projeções refeitas dele.
2. **Cada dado tem um dono.** O núcleo nunca recalcula número oficial do ERP.
3. **Origem com nível de prova.** Observada, declarada, inferida ou desconhecida; o que falta não é completado.
4. **Identidade só por igualdade exata.** Fundir fichas é decisão humana registrada e reversível.
5. **Mesmas ferramentas para pessoas e IA.** Papel, permissão, aprovação e chave contra repetição em cada chamada.
6. **Dado pessoal à parte.** Cifrado, de acesso restrito, apagável; o mínimo sai para fora.
7. **Peças trocáveis.** Chatwoot, provedor de IA e hospedagem saem sem reescrever o núcleo.
8. **Simples de operar.** Menos peças vence mais desempenho que ninguém pediu.

> **Resposta objetiva:** o volume esperado é pequeno para um banco e um processo; a forma do sistema é decidida pela confiabilidade da origem, pela LGPD e pela operação por uma pessoa.

---

2. Contexto, serviços e topologia



Visão de contexto e topologia. Nenhum servidor recebe conexão de fora: o cloudflared abre o túnel de dentro para fora. Webhooks entram pela borda com assinatura conferida no núcleo; tudo que sai passa pela caixa de saída do core-worker; o PostgreSQL manda o WAL sem parar para o S3 em São Paulo; o OpenTelemetry Collector envia a telemetria ao serviço de observabilidade (seção 11).

Serviços e onde rodam

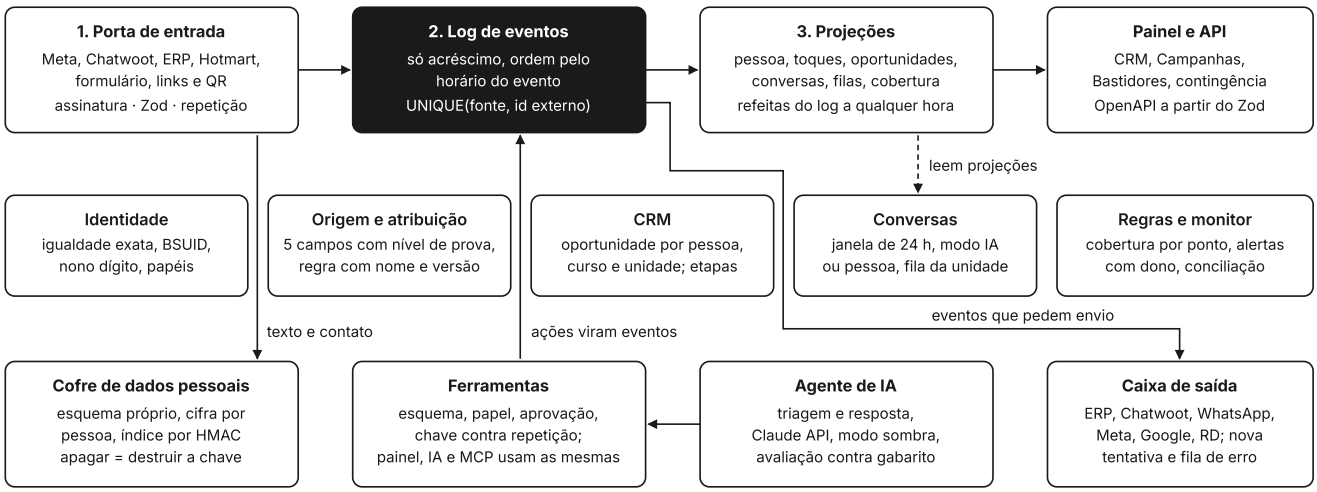
Serviço	Faz	Tecnologia	Escala inicial	Acesso
`core-api`	recebe webhooks e formulários, serve o painel e a API, resolve links curtos e QR, expõe as ferramentas por MCP	Node.js 26 LTS, Hono, Zod	2 processos	`hooks.`, `go.`, `app.`
`core-worker`	fila, caixa de saída, agente de IA, monitor de cobertura, conciliações	o mesmo código, outro processo; pg-boss 12	1 a 2 processos	sem porta pública
painel	CRM, Campanhas, Bastidores e tela de atendimento de contingência	React 19, Vite, Tailwind, shadcn	arquivos estáticos	`app.` com Access

PostgreSQL do núcleo	log de eventos, cofre, projeções, fila, caixa de saída	PostgreSQL 18	1 instância; RDS na fase de 90 dias	só rede interna
Chatwoot	caixa de atendimento das unidades, com o canal API ligado ao núcleo e a ficha da pessoa numa aba de app de painel	Chatwoot Community v4.19.1 (Rails, Sidekiq), fork MIT sem `enterprise/`	1 web + 1 Sidekiq; mínimo de 4 vCPU e 4 GB	`atendimento.` com Access
PostgreSQL e Redis do Chatwoot	dados e fila do Chatwoot	PostgreSQL com pgvector; Redis 7 ou mais novo (exigências do Chatwoot)	1 + 1	só rede interna
`cloudflared`	túnel de saída até a Cloudflare	Cloudflare Tunnel	2 réplicas	só saída
OpenTelemetry Collector	junta logs, métricas e rastros e envia ao serviço de observabilidade	OpenTelemetry	1	só saída
Metabase (fase de 90 dias)	painéis do Grande Cérebro sobre a réplica de leitura	Metabase OSS v0.64 (AGPL)	1	`bi.` com Access

> **Resposta objetiva:** cinco peças próprias (api, worker, painel, banco e túnel) e uma adotada (Chatwoot). Nada fica exposto: a equipe entra com SSO pela Cloudflare, e os parceiros, por webhooks assinados.

---

3. O núcleo por dentro



Componentes do núcleo. A seta cheia é escrita; a tracejada, leitura. Os módulos de domínio leem as projeções e gravam as decisões no log pelas ferramentas. Toda mudança de estado passa pelo log, e por isso cada ação de pessoa ou da IA tem autor, motivo e base registrados.

Módulos

Módulo	Responsabilidade	É dono de
Porta de entrada	um adaptador por fonte; confere assinatura, valida com limites de tamanho, grava o bruto necessário e responde	contratos de entrada
Log de eventos	registro só de acréscimo, ordenado pelo horário do evento, com causa e correlação	a história completa
Cofre	nome, telefone, e-mail e texto de mensagem, cifrados com uma chave por pessoa; busca por HMAC	dado pessoal
Identidade	casa pessoa por BSUID, telefone (com a regra do nono dígito), e-mail ou id do ERP; propõe fusões	pessoa e papéis (aluna, paciente, lead)
Origem e atribuição	toques com os 5 campos e o nível de prova; regra de atribuição versionada; prévia de regra nova	origem e atribuição

CRM	oportunidade por pessoa, curso e unidade; etapas até a pré-matrícula; "ganha" só pelo ERP	oportunidade
Conversas	estado de cada conversa: janela de 24 h, modo IA ou pessoa, fila da unidade, espelho no Chatwoot	roteamento
Regras e monitor	cobertura por ponto de entrada, alertas com ação e dono, conciliação com plataformas e ERP	alertas e status dos pontos
Ferramentas	registro tipado das ações, com papel, aprovação e chave contra repetição	política de ação
Agente de IA	triagem, resposta com dado lido do ERP, passagem para pessoa	nada: só age por ferramentas
Caixa de saída	entrega para fora com nova tentativa, espera crescente e fila de erro	pendências de envio

Modelo de dados

- `log.events`: `seq`, `type`, `schema`, `source`, `external_id`, `occurred_at`, `recorded_at`, `actor`, `reason`, `based_on`, `correlation_id`, `payload` (jsonb, só referências ao cofre). `UNIQUE(source, external_id)`; gatilho e permissões impedem UPDATE e DELETE.
- `pii.keys` e `pii.values`: chave de dado por pessoa, cifrada pela chave mestra; valores cifrados e HMAC para busca. Só o papel do cofre lê esse esquema.
- `app.*`: projeções (pessoas, identificadores, papéis, toques, oportunidades, conversas, filas, pontos de entrada, links, leituras de QR, alertas, cobertura).
- `ops.*`: caixa de saída, fila do pg-boss, quarentena, chaves de ferramentas, controle de migrações.

```
{
  "seq": 184233,
  "type": "whatsapp_message_received",
  "schema": 2,
  "source": "meta",
  "external_id": "wamid.HBgL...",
  "occurred_at": "2026-11-03T14:10:05-03:00",
  "actor": "system:gateway",
  "correlation_id": "conv_sp_8f2c",
  "payload": {
    "business_number": "sp",
    "person_ref": "pii:7f3c...",
    "text_ref": "pii:a91e...",
    "referral": {
      "source_id": "120226...",
      "ctwa_clid": "Aff-n8..."
    }
  }
}
```

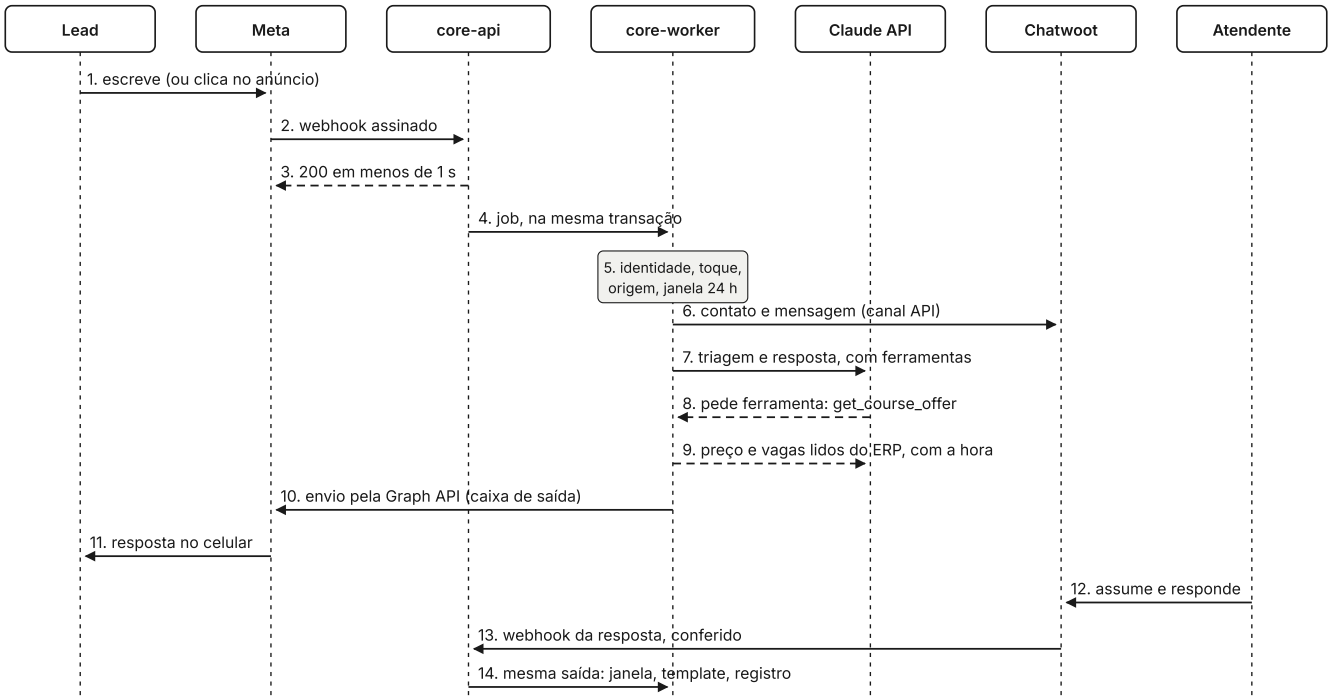
Regras de consistência

- **Escrever** é inserir no log e atualizar as projeções na mesma transação. Se a projeção falha, o evento fica e vai para a quarentena, revisada todo dia e reprocessada com a mesma chave.
- **Ordem** é o horário do evento, não o de chegada. Evento atrasado entra no lugar certo; a projeção afetada é refeita.
- **Regra nova** (atribuição, monitor) roda primeiro como prévia sobre o log inteiro e só depois vira padrão, com a versão gravada em cada conclusão.
- **Refazer tudo** a partir do log é um comando; é ensaiado todo mês contra a cópia restaurada do backup.

> **Resposta objetiva:** tudo que acontece vira um evento imutável; o resto é visão calculada. Isso dá auditoria completa, correção sem apagar e mudança de regra com prévia.

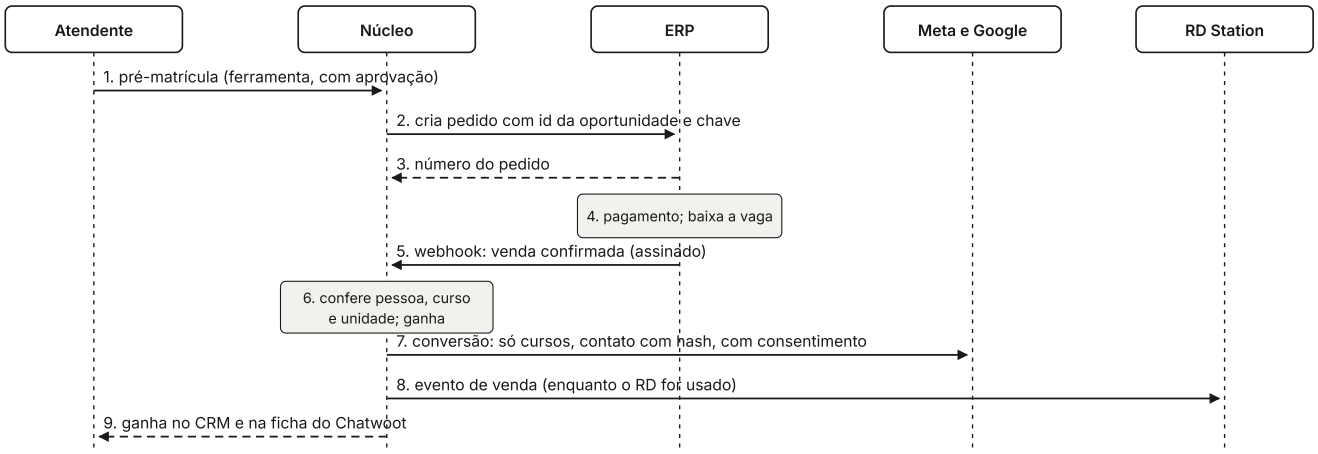
4. Fluxos principais

WhatsApp: da mensagem do lead à resposta da IA e da atendente



Um único ponto recebe da Meta e um único ponto envia. Assim a origem do anúncio (referral e `ctwa_clid`) é gravada antes de qualquer outra coisa, a janela de 24 horas e as regras de template valem para a IA e para as pessoas, e trocar o Chatwoot não mexe no WhatsApp.

Venda: da pré-matrícula à conversão nas plataformas



Se pessoa, curso ou unidade não batem, a venda vai para a fila de conciliação e nada vira "ganha". Se o ERP não avisa (P4), uma conciliação diária puxa as vendas e cai no mesmo caminho a partir do passo 5.

Outros caminhos

- **LP e formulário.** A página guarda UTMs, `gclid`, `fbclid`, `_fbc` e `_fbp` no primeiro acesso e envia tudo com o formulário ao núcleo, que grava, abre a oportunidade e repassa ao RD pela caixa de saída. Se o núcleo não responde, o formulário vai direto ao RD (caminho de volta) e a conciliação semanal recupera o lead.
- **Link curto e QR.** `go.<domínio>/K7P2` grava a leitura (sem dado pessoal) e redireciona para o WhatsApp com o código no texto, ou para a LP com as UTMs. O código vira os 5 campos quando a mensagem chega.
- **Hotmart.** O webhook traz o `sck` com o código curto; a venda é ligada à jornada pelo código e conciliada com o ERP, que continua a fonte oficial.
- **Paciente modelo.** A IA só encaminha para a agenda da unidade; dado clínico não entra no núcleo além da conversa, guardada no cofre com acesso restrito (P7).

Falhas e como o sistema reage

Falha	Como é percebida	O que acontece
Webhook repetido	chave única do log	descartado e contado; nenhum efeito duplicado
Núcleo fora do ar	verificação externa a cada minuto	Meta reenvia por até 7 dias, Hotmart até 5 vezes; formulários vão ao RD; nada se perde
ERP fora do ar	item mais velho da caixa de saída acima de 15 min	nova tentativa com espera crescente; a IA avisa e passa para pessoa; alerta ao profissional
Chatwoot fora do ar	erro na entrega à API do Chatwoot	mensagens seguem no log; reenvio quando volta; atendimento de contingência na tela do núcleo
Token da Meta inválido	primeiro 401 da Graph API	alerta imediato; envios param na caixa de saída até a troca, sem perda
Evento malformado	validação na borda	400 para quem enviou; nada é gravado
Evento válido que quebra a projeção	erro na transação	evento fica, entra na quarentena e é reprocessado depois da correção
Venda sem oportunidade	conferência no passo 6	fila de conciliação com sugestão; uma pessoa decide
Fusão de fichas errada	revisão humana	desfeita por evento; projeções refeitas

> **Resposta objetiva:** entra por um só lugar, sai por um só lugar, e cada passo grava antes de agir. Falha de parceiro vira espera com nova tentativa, nunca perda de dado ou venda duplicada.

---

5. Integrações

Sistema	Direção e forma	Autenticação	Chave contra repetição	Se falhar
WhatsApp Cloud API (Meta)	entra por webhook; sai por `POST /{phone-number-id}/messages` na Graph API v26.0	assinatura `X-Hub-Signature-256` com o app secret; token de usuário do sistema	`wamid`; `wamid` + status	Meta reenvia por até 7 dias; envio fica na caixa de saída
Chatwoot	dois sentidos pelo canal API: o núcleo cria contato, conversa e mensagem; o Chatwoot avisa as respostas da equipe na URL de callback; uma aba de app de painel mostra a ficha	token de acesso da conta; segredo que o Chatwoot gera para verificar o webhook; tráfego só na rede interna	id da mensagem	conciliação a cada 5 min pela API do Chatwoot
ERP	sai: pedido com id da oportunidade; entra: venda, cancelamento e estorno; consulta de catálogo e vagas	token e assinatura HMAC (a combinar, P4)	id da venda; id da oportunidade no pedido	conciliação diária; sem API, exportação diária e fila de conciliação
Hotmart	entra: webhook 2.0.0 (aprovada, completa, cancelada, reembolsada, chargeback)	`X-HOTMART-HOTTOK`	id do evento e transação	reenvio até 5 vezes; histórico de 60 dias
RD Station Marketing	sai durante a transição: eventos `conversion` e `sale`	token da API	id do evento	caixa de saída; o formulário também pode ir direto
Meta (Conversions API)	sai: Lead e Purchase de cursos, com `fbc`, `fbp`, `ctwa_clid` e e-mail e telefone com hash	token de acesso	`event_id`	caixa de saída; janela de 7 dias para o evento
Google Ads (Data Manager API)	sai: conversões offline com `gclid`, `gbraid` ou `wbraid` e dados com hash	OAuth	id do pedido	caixa de saída

GA4 e GTM	auditoria e leitura; nenhum dado pessoal em URL	conta da Clinic	—	—
Claude API (Anthropic)	sai: Messages API com ferramentas e saída estruturada	chave por ambiente, com limite de gasto	id da mensagem do lead	sem resposta no tempo limite, passa para pessoa
Provedor de identidade	entra: SSO da equipe pela Cloudflare Access	OIDC	—	acesso de emergência com conta guardada e auditada

Dados de saúde nunca vão para Meta e Google (Termos das Business Tools §1.h; LGPD art. 11). Eventos de conversão só saem com consentimento por finalidade registrado como evento.

> **Resposta objetiva:** cada integração tem autenticação, chave contra repetição e um plano para quando o outro lado falha. O ERP é a única peça com contrato ainda a combinar (P4), e o desenho já prevê conciliação se ele não avisar.

---

6. IA e agentes

Como o agente funciona

1. **Filtro antes do modelo.** Palavras de saúde (dor, inchaço, hematoma, reação, intercorrência) e de reclamação vão direto para pessoa. Janela de 24 horas fechada: nada automático.
2. **Triagem.** Uma chamada com saída estruturada devolve intenção, unidade, curso, confiança e se o assunto é sensível. Abaixo de 0,85 de confiança, passa para pessoa.
3. **Resposta.** O modelo recebe só o texto da conversa e uma ficha mínima (sem telefone nem e-mail) e age por ferramentas: lê preço e vagas do ERP, registra origem declarada, abre a oportunidade, encaminha e responde.
4. **Registro.** Cada chamada de ferramenta vira evento com autor "IA", motivo e base. Em modo sombra, a resposta é gravada sem envio, para comparar com a pessoa.

Ferramentas e permissões

Ferramenta	IA	Atendente	Gestor	Regra
`get_course_offer`, `explain_origin`, `origin_coverage`	sim	sim	sim	leitura; resposta com fonte e hora
`route_conversation`, `record_declared_origin`	sim	sim	sim	automático
`open_opportunity`	com confiança ≥ 0,85	sim	sim	uma por pessoa, curso e unidade
`reply_to_conversation`	só na janela e com dado lido	sim	sim	sai pela caixa de saída
`set_conversation_mode`	só para passar a pessoa	sim	sim	automático
`advance_opportunity`	não	sim	sim	só avança; "ganha" vem do ERP
`request_enrollment`	prepara	aprova	sim	vira pedido no ERP
`propose_merge` / `approve_merge`	propõe	propõe	aprova	reversível por evento
`set_entry_point_status`	não	não	libera	rebaixar é automático; liberar exige teste
`send_template` (produção)	não	com aprovação	sim	exige opt-in registrado
`record_consent`, `erase_person` (produção)	não	consentimento	encarregado apaga	apagamento com dupla confirmação

Modelos e custo

A escolha sai do teste, não da tabela de preços: o mesmo conjunto de conversas avaliadas (o gabarito das correções humanas) mede acerto, passagem para pessoa, latência e custo por conversa resolvida. A primeira medição usa o modelo mais capaz com esforço baixo; um modelo menor só entra numa rota se empatar no gabarito.

Modelo (Claude API)	Entrada / saída por milhão de tokens	Papel candidato	Custo estimado por 1.000 conversas
Claude Opus 5.5 (`claude-opus-5-5`)	US$ 4 / US$ 20	resposta com ferramentas, esforço baixo; primeira medição	≈ US$ 60
Claude Sonnet 5.5 (`claude-sonnet-5-5`)	US$ 2 / US$ 10	resposta com ferramentas	≈ US$ 30
Claude Haiku 5.5 (`claude-haiku-5-5`)	US$ 0,10 / US$ 0,50	triagem com saída estruturada	≈ US$ 1,60

Premissas da estimativa: 4 turnos de IA por conversa; prefixo fixo de 5 mil tokens (instruções e ferramentas) servido do cache; 1,5 mil tokens novos de entrada e 400 de saída por turno, raciocínio incluído, contados no tokenizador atual; leitura de cache a US$ 0,20 (Opus 5.5), US$ 0,10 (Sonnet 5.5) e US$ 0,01 (Haiku 5.5) por milhão de tokens; escrita de cache diluída pelo tráfego contínuo. Preços de lista da Anthropic em 30/10/2026 (seção 16). Com 6 mil conversas por mês: cerca de US$ 360 só com Opus 5.5, US$ 180 com Sonnet 5.5, ou perto de US$ 10 se a triagem em Haiku 5.5 resolver a maior parte. Avaliações em lote saem pela Batch API, com 50% de desconto. A conta real sai do uso medido.

Controles

- **Contexto mínimo.** Nenhum telefone ou e-mail vai ao modelo; as ferramentas do agente só alcançam a pessoa da conversa, então uma mensagem maliciosa não chega a outra ficha.
- **Saídas verificadas.** Ferramentas com esquema estrito; saída estruturada na triagem; respostas com número só se vierem de ferramenta de leitura do ERP; recusa do modelo tratada como passagem para pessoa.
- **Custo sob controle.** Instruções e ferramentas fixas no começo do pedido para aproveitar o cache; limite de gasto por chave e por ambiente; alerta de custo por conversa.
- **Dados no fornecedor.** A API não treina com os dados por padrão; Opus, Sonnet e Haiku 5.5 aceitam retenção zero por acordo com a Anthropic. A inferência roda nos EUA ou na rede global (não há região no Brasil), então o uso entra como transferência internacional, com cláusulas-padrão (seção 9).
- **Troca de provedor.** A camada que chama o modelo é fina; ferramentas, instruções e histórico ficam com a Clinic. As mesmas ferramentas saem por MCP para qualquer modelo; o candidato novo roda em modo sombra contra o gabarito antes de entrar.
- **Política do WhatsApp.** Atendimento automatizado com passagem para pessoa é permitido; os Termos §4.7 restringem "provedores de IA". A leitura é que um bot da própria Clinic fica fora; o jurídico confirma antes da fase 2.

> **Resposta objetiva:** o agente é um usuário a mais das ferramentas, com menos permissões; o modelo é escolhido por teste contra o gabarito humano, e o custo de IA para 6 mil conversas fica entre US$ 10 e US$ 360 por mês, conforme o modelo que passar no teste.

---

7. Dados e Grande Cérebro

- **Fonte de análise.** Na fase de 90 dias, uma réplica de leitura do PostgreSQL alimenta um esquema analítico com visões estáveis: funil por unidade, canal e campanha, com a regra de atribuição e a versão à vista; cobertura de origem por ponto; vendas e vagas copiadas do ERP todo dia.
- **Ferramentas.** Metabase para painéis da gestão; Python (pandas ou DuckDB) para análises, num processo separado que só lê a réplica; agentes de análise usam ferramentas MCP somente de leitura.
- **Agente de tráfego.** Um job diário lê investimento por campanha nas APIs de anúncios da Meta e do Google e grava como evento; a tela Campanhas cruza campanha, investimento, leads, vendas confirmadas e vagas. Mudar verba é sugestão com aprovação humana.

- **Números oficiais.** Vendas, saldo, vagas, comissões e DRE ficam no ERP; o núcleo mostra e cita a fonte e a hora da leitura.

"Por que Campinas vendeu menos nesta semana?" A resposta segue uma ordem fixa: (1) qualidade da origem em Campinas (cobertura, alertas, pontos em auditoria); (2) números oficiais do ERP (vendas, cancelamentos, turmas lotadas); (3) funil do núcleo por canal, com regra e janela de atribuição; (4) investimento por campanha; (5) hipóteses ordenadas com evidência. A regra de atribuição aparece na resposta, e semanas com poucas vendas não sustentam conclusão forte.

> **Resposta objetiva:** as análises leem uma cópia, nunca o banco de produção, e sempre dizem qual regra de atribuição usaram; o número oficial continua no ERP.

---

8. Segurança

Área	Controle
Acesso da equipe	Cloudflare Access na frente do painel, do Chatwoot e do Metabase, com SSO e MFA do provedor de identidade da Clinic; papéis por unidade no núcleo; caixas por unidade no Chatwoot; revisão de acessos todo mês e na saída de pessoas
Rede	túnel de saída; nenhuma porta aberta; SSH só pela Access; firewall que nega tudo por padrão; banco só na rede interna
Aplicação	assinatura conferida em todo webhook; validação com limites de tamanho; regras gerenciadas do WAF na borda (no plano Free, o conjunto gratuito; o conjunto completo e o OWASP pedem o plano Pro) e limite de requisições no núcleo; cabeçalhos de segurança (CSP, HSTS); dependências fixadas e revisadas automaticamente; instalação sem scripts de pacote
Dados	TLS em todo o trajeto; cifra de campo no cofre (AES-256-GCM, chave por pessoa, chave mestra fora do banco); backups cifrados; logs sem dado pessoal
Segredos	SOPS com age no repositório de infraestrutura, injetados no deploy; rotação a cada trimestre e na saída de pessoas; chaves separadas por ambiente
Auditoria	toda ação de pessoa ou IA vira evento com autor, motivo e base; leitura de dado sensível também gera evento
Incidentes	runbook de resposta; comunicação à ANPD e aos titulares em até 3 dias úteis (Resolução CD/ANPD nº 15/2024)

---

9. LGPD

Classe	Exemplos	Onde fica	Quem acessa	Pode sair para
Pública	cursos, turmas, preços	ERP; cópia no núcleo	todos	site, IA
Operacional	eventos sem pessoa, campanhas, códigos	log, projeções	equipe	painéis
Pessoal	nome, telefone, e-mail, ids	cofre cifrado	atendimento da unidade	Meta e Google só com hash e consentimento; RD na transição
Sensível (saúde)	queixa clínica, dado de paciente modelo	cofre com acesso restrito; prontuário no sistema clínico (P7)	equipe clínica	nunca para marketing; IA só com base legal e no mínimo

- **Bases legais por finalidade.** Atendimento e matrícula: procedimentos preliminares e execução de contrato (art. 7º, V). Marketing e conversões para anúncios: consentimento (art. 7º, I). Dado de saúde: consentimento específico e destacado (art. 11). Cada consentimento e cada revogação viram evento, e a revogação desliga as automações daquela finalidade.
- **Direitos do titular.** Acesso e portabilidade: exportação gerada do log e do cofre. Correção: evento de correção. Eliminação: destruir a chave da pessoa torna ilegível o que está no banco e nos backups, sem reescrever o log. Prazos do art. 19.

- **Transferência internacional.** Meta, Google e Anthropic processam fora do Brasil (a Claude API só oferece inferência nos EUA ou global): cláusulas-padrão contratuais da ANPD (Resolução CD/ANPD nº 19/2024) e envio do mínimo necessário (art. 33). Servidores, banco e backups ficam em São Paulo.
- **Retenção (proposta para o jurídico).** Lead sem matrícula: 24 meses após o último contato; aluno e paciente: prazo do contrato mais o prazo legal; logs técnicos: 90 dias. Expirado o prazo, a chave da pessoa é destruída.
- **Relatório de impacto.** RIPD antes da fase 2 para dado de saúde e uso de IA, com o encarregado de dados.

> **Resposta objetiva:** o dado pessoal mora num cofre cifrado por pessoa, sai só com base legal e no mínimo, e apagar uma pessoa é destruir a chave dela, inclusive nos backups.

---

10. Infraestrutura e implantação

Topologia por fase

Fase	Máquinas	Banco	O que entra
2 semanas: modo sombra	1 servidor AWS Lightsail em São Paulo, 16 GB e 4 vCPU (US$ 84/mês), com Coolify v4	PostgreSQL no próprio servidor, WAL contínuo no S3 São Paulo	núcleo recebendo cópia dos eventos, gerador de links e QR, painel de cobertura; atendimento segue no fornecedor atual
30 dias: piloto em 1 unidade	o mesmo servidor + Chatwoot; staging em Lightsail 4 GB (US$ 24/mês), que também roda a verificação externa	idem; Chatwoot com PostgreSQL e Redis próprios	número de WhatsApp da unidade piloto no núcleo e no Chatwoot; IA em modo sombra; venda do ERP ligada à jornada
90 dias: 3 unidades	núcleo em Lightsail 8 GB e 2 vCPU (US$ 44/mês); Chatwoot em Lightsail 16 GB e 4 vCPU, o mínimo dele (US$ 84/mês)	RDS for PostgreSQL em São Paulo, db.t4g.medium Multi-AZ, com recuperação ponto a ponto, ligado ao Lightsail por peering de VPC; réplica de leitura quando o Grande Cérebro começar	todas as unidades; IA na fase 2 se passar no gabarito; Metabase

Domínios e ambientes

- **Domínios:** `app.` (painel), `atendimento.` (Chatwoot), `hooks.` (webhooks), `go.` (links curtos e QR), `bi.` (Metabase), cada um com o seu ambiente de staging.
- **Ambientes:** local (o `docker compose` da demo), staging (dados sintéticos e número de teste da Meta) e produção. Dado real só em produção.

Pipeline

1. **Pull request:** checagem de tipos, testes, `verify` dos cenários, auditoria de dependências e revisão.
2. **Merge na main:** imagem Docker com o commit como tag, publicada no GitHub Container Registry; deploy automático no staging e teste de fumaça.
3. **Produção:** aprovação manual no GitHub; deploy pelo webhook do Coolify; as migrações rodam antes da troca de imagem.
4. **Voltar atrás:** reimplantar a imagem anterior. As migrações seguem o padrão expandir e contrair: nenhuma quebra a versão que está no ar.

Backup e recuperação

- **Núcleo:** pgBackRest com WAL contínuo, cópia completa semanal e diferencial diária no S3 em São Paulo, cifrado; retenção de 35 dias com versionamento do bucket.
- **Chatwoot:** cópia diária do banco e anexos no mesmo S3.
- **Ensaio:** todo mês, restauração cronometrada no staging, com `verify` e refazimento das projeções. Sem ensaio, o backup não conta como existente.
- **Fase de 90 dias:** banco gerenciado com réplica síncrona e recuperação ponto a ponto; o pgBackRest continua como segunda cópia, fora do provedor do banco.

> **Resposta objetiva:** um servidor no começo, dois servidores e banco gerenciado nas três unidades; tudo versionado, com deploy aprovado em um clique, volta à versão anterior em minutos e restauração ensaiada todo mês.

---

11. Observabilidade e operação

O núcleo emite logs estruturados sem dado pessoal, métricas e rastros com OpenTelemetry, seguindo cada evento do webhook ao envio. O coletor manda tudo para o Grafana Cloud no plano gratuito (10 mil séries de métricas, 50 GB de logs e 50 GB de rastros por mês, 14 dias de retenção, 3 usuários); erros de código vão para o Sentry no plano Developer (1 usuário, 5 mil erros por mês). Uma verificação externa a cada minuto, com Uptime Kuma no servidor de staging (outra máquina), confere `hooks.`, `app.` e `atendimento.`.

Sinal	Limite	Quem recebe	Ação
Webhooks com erro 5xx	acima de 1% em 5 min	profissional	runbook de entrada
Caixa de saída parada	item mais velho acima de 15 min	profissional	ver o destino (ERP, Meta, Chatwoot)
Quarentena	qualquer evento novo	profissional	revisão diária
Primeira resposta da IA	p95 acima de 20 s	profissional	ver fila e tempo do modelo
Passagem para pessoa	acima de 40% num dia	coordenação	revisar triagem e gabarito
Cobertura de origem	3 leads seguidos sem campanha num ponto com 90% de base	dono do ponto	ponto volta para "em auditoria"
Conciliação semanal	diferença acima de 5%	profissional e marketing	investigar o ponto
Backup	WAL atrasado 10 min ou cópia com mais de 26 h	profissional	runbook de backup
Token ou certificado	vencendo em 14 dias	profissional	trocar
Máquina	disco acima de 80%; CPU acima de 80% por 15 min	profissional	ver seção 12

- **Runbooks:** entrada falhando; ERP fora; token da Meta; Chatwoot fora (contingência na tela do núcleo); restauração do banco; vazamento de credencial; apagamento a pedido do titular.
- **Rotina:** todo dia, 15 minutos (quarentena, alertas, caixa de saída); toda semana, conciliação; todo mês, ensaio de restauração, revisão de acessos, atualização de dependências e revisão de 60 leads do checklist.
- **Fora do horário:** só alertas críticos acordam alguém (entrada parada, backup parado, caixa de saída parada há mais de 1 hora); o resto espera o dia útil. Com uma pessoa, isso é um combinado com o fundador.

---

12. Escala e evolução

Sinal	Limite	Próximo passo
Tamanho do log	mais de 50 milhões de eventos ou consulta lenta	particionar por mês e arquivar o frio no S3
CPU do núcleo	acima de 70% por dias	mais processos do worker, depois worker em outra máquina
Atendimento	mais de 50 atendentes ou lentidão	Chatwoot em máquina maior, Sidekiq separado
Análises pesando	consultas longas no primário	réplica de leitura (já prevista na fase de 90 dias)
Nova unidade	decisão do negócio	cadastro: código, número, pontos de entrada e turmas; sem código novo

Nova fonte de lead ou canal	decisão do negócio	um adaptador na porta de entrada; Instagram entra pelo Chatwoot
Equipe técnica cresce	mais de 3 pessoas mexendo no mesmo módulo	separar o módulo em serviço só se o deploy conjunto virar gargalo

> **Resposta objetiva:** cada passo de crescimento tem um sinal que o dispara; nada é separado antes de doer, e unidades e canais novos entram por cadastro ou por um adaptador.

---

13. Custos mensais estimados

Preços de lista consultados em 30/10/2026, sem impostos (nenhuma das páginas informa tributos) e sem conversão de moeda. Fora da conta: o salário do profissional dedicado, domínios e o plano do GitHub que a Clinic já tiver.

Infraestrutura (US$ por mês)

Item	Piloto (30 dias)	3 unidades (90 dias)	Base do preço
Servidor do núcleo (AWS Lightsail, São Paulo)	84,00	44,00	16 GB e 4 vCPU no piloto, com o Chatwoot junto; depois 8 GB e 2 vCPU
Servidor de atendimento (Chatwoot)	—	84,00	16 GB e 4 vCPU; o Chatwoot pede no mínimo 4 vCPU e 4 GB
Staging e verificação externa	24,00	24,00	Lightsail 4 GB e 2 vCPU
PostgreSQL gerenciado (RDS, São Paulo)	—	222,65	db.t4g.medium Multi-AZ a US$ 0,275/h × 730 h, mais 50 GB gp3 a US$ 0,438
S3 em São Paulo (backups e anexos)	4,05	8,10	100 GB e 200 GB a US$ 0,0405 por GB-mês
Cloudflare (Free e Zero Trust Free)	0,00	0,00	DNS, CDN, TLS, DDoS, WAF gratuito; Access e Tunnel até 50 usuários
Observabilidade (Grafana Cloud Free, Sentry Developer)	0,00	0,00	cabe nos limites gratuitos (seção 11)
Licenças (Chatwoot Community, Coolify, Metabase OSS, pgBackRest, pg-boss)	0,00	0,00	código aberto
Total	**≈ 112**	**≈ 383**	**com a réplica de leitura para análise (+ US$ 110,96): ≈ 494**

Uso (por mês)

Item	Piloto (1 unidade)	3 unidades	Premissas
WhatsApp: mensagens de serviço	R$ 385,00	R$ 1.120,00	12 mil e 35 mil respostas dentro da janela; 1.000 grátis por número por mês; depois, R$ 0,035 cada
WhatsApp: templates utility	R$ 35,00	R$ 105,00	1 mil e 3 mil confirmações e lembretes a R$ 0,035
WhatsApp: templates marketing	R$ 225,19	R$ 643,40	700 e 2 mil reativações com opt-in, a R$ 0,3217
WhatsApp, total	**≈ R$ 645**	**≈ R$ 1.868**	**mensagens recebidas não são cobradas**
IA (Claude API)	US$ 3 a 120	US$ 10 a 360	2 mil e 6 mil conversas; de Haiku 5.5 a Opus 5.5 (seção 6)

- **Mudança recente que pesa.** Desde 01/10/2026 a Meta cobra mensagens de serviço acima de 1.000 por número por mês e utility dentro da janela de 24 horas. Conversas que nascem de anúncio de clique para WhatsApp têm uma janela de até 7 dias sem cobrança quando a Clinic responde a tempo, o que baixa a conta das campanhas. A Meta só reajusta preço no início de cada trimestre, e contas de clientes do Brasil precisam passar a faturar em reais até 30/06/2027.

- **Banco gerenciado mais barato.** O RDS Single-AZ com recuperação ponto a ponto custa cerca de US$ 111 por mês (instância e 50 GB); o Multi-AZ dobra a instância em troca de failover automático. O Supabase em São Paulo (Pro de US$ 25 mais US$ 100 de recuperação ponto a ponto por 7 dias, compute maior a cotar) é a alternativa.
- **Hostinger como alternativa no piloto.** KVM 4 (4 vCPU, 16 GB, 200 GB NVMe) e KVM 2 de staging custam R$ 102,98 por mês nos 24 meses promocionais, pagos adiantado, e R$ 227,98 na renovação, mais o S3. Na fase de 90 dias não há banco gerenciado na mesma rede: o PostgreSQL seria operado pelo profissional, com réplica própria.

> **Resposta objetiva:** cerca de US$ 112 por mês de infraestrutura no piloto e US$ 383 nas três unidades; o maior custo variável passa a ser o WhatsApp, perto de R$ 1.870 por mês nas três unidades, e a IA fica entre US$ 10 e US$ 360, conforme o modelo que passar no teste.

---

14. Roteiro técnico

Fase	Implanta	Critério para avançar	Como recuar
2 semanas	servidor, Cloudflare, núcleo em modo sombra, gerador de links e QR, 4 pontos corrigidos, backups com ensaio	4 pontos com teste ponta a ponta; cobertura medida por ponto	nada a desfazer: o núcleo só observa
30 dias	Chatwoot e canal API, número da unidade piloto, ligação com o ERP, IA em modo sombra, staging	checklist de liberação cumprido (7 critérios do documento principal)	formulários direto ao RD em menos de 1 hora; número volta ao fornecedor atual
90 dias	três unidades, banco gerenciado, segundo servidor, Metabase, IA na fase 2 se passar no gabarito	três unidades no checklist; acerto da triagem na meta combinada	unidade volta ao fornecedor; os dados seguem no log

---

15. Decisões e riscos

Decisão	Alternativa considerada	Por quê	Revisitar quando
Monólito modular	microsserviços	uma pessoa, um deploy, transação única entre log e projeção	equipe maior com deploys disputados
Log de eventos no PostgreSQL	Kafka ou banco de eventos dedicado	volume pequeno; um banco para operar; SQL para auditar	milhões de eventos por dia
Fila e caixa de saída no PostgreSQL (pg-boss)	Redis, RabbitMQ ou SQS	gravar o evento e o pedido de envio na mesma transação; uma peça a menos	milhares de jobs por segundo
Núcleo recebe da Meta e alimenta o Chatwoot pelo canal API	inbox nativa do Chatwoot, com o núcleo ouvindo os webhooks dele	origem gravada antes de tudo; um só ponto de envio; Chatwoot trocável	se o piloto precisar acelerar: começar pela nativa e trocar antes da expansão
WhatsApp Cloud API direto	parceiro BSP	sem taxa intermediária; controle do webhook e da origem	se a Clinic quiser suporte contratado do canal
AWS em São Paulo: Lightsail com Coolify, S3 e, nas três unidades, RDS	Hostinger no Brasil (mais barata no piloto); contêineres gerenciados (ECS)	um provedor e uma região; rede privada até o banco; dados no Brasil; sem migração no meio do caminho	se o custo pesar mais que a operação, ou se a equipe crescer
Chatwoot Community, fork MIT	construir a caixa; Chatwoot pago	caixa pronta em dias; recursos pagos não são necessários	se SSO nativo ou SLA virarem exigência
Claude API com ferramentas próprias e MCP	plataforma de bot fechada	ferramentas, histórico e gabarito ficam com a Clinic	a cada modelo novo, pelo gabarito

Cofre com chave por pessoa	apagar linhas	apaga também nos backups sem reescrever o log	—
Cloudflare Access para a equipe	construir login	SSO e MFA sem código; uma porta só	mais de 50 usuários (o plano gratuito vai até 50; depois, US$ 7 por usuário por mês)

Risco	Efeito	Mitigação
Dependência de uma pessoa	parada se ela sair ou adoecer	uma linguagem, poucos serviços, runbooks, decisões registradas, acesso de emergência com o fundador
Política do WhatsApp para IA	bloqueio do número	API oficial, passagem para pessoa, IA por fases, parecer jurídico antes da fase 2
ERP sem API ou sem aviso de venda (P4)	venda sem ligação automática	conciliação diária e fila de conciliação; id da oportunidade na matrícula
Mudança no Chatwoot	quebra na integração	versão fixada, fork MIT, testes do canal API no staging antes de atualizar
Servidor único nas fases iniciais	indisponibilidade	reenvio dos parceiros, backup contínuo com ensaio, banco gerenciado na fase de 90 dias
Custo de IA acima do previsto	conta alta	limite por chave, cache, modelo escolhido por teste, alerta de custo por conversa
Preço do WhatsApp (serviço cobrado desde 01/10/2026)	custo por conversa sobe	custo por conversa no painel; janela gratuita de anúncio aproveitada; templates só com opt-in e propósito claro; revisão a cada trimestre, quando a Meta reajusta
Vídeo dos cursos online	termos da Cloudflare pedem serviço pago para vídeo	vídeos continuam na Hotmart; o sistema não serve vídeo

> **Resposta objetiva:** cada escolha tem alternativa e gatilho para revisão; os riscos maiores (pessoa única, política do WhatsApp, ERP) têm mitigação desenhada desde o piloto.

---

16. Fontes

Consultadas em 30/10/2026, salvo indicação. Os fatos de WhatsApp, anúncios, Hotmart, RD e LGPD vêm da pesquisa de 28 e 29/10/2026 do documento principal (`docs/processo/pesquisa/`).

- **Versões:** PostgreSQL 18.6, suporte até 14/11/2030 (postgresql.org/support/versioning); Node.js 26 "Lithium" em Active LTS desde 28/10/2026, fim de vida em 30/04/2029 (github.com/nodejs/Release, schedule.json); Chatwoot v4.19.1 de 24/10/2026 (github.com/chatwoot/chatwoot/releases); pg-boss 12.38.0, MIT, PostgreSQL 13+ (github.com/timgit/pg-boss); Coolify v4.5.3, Apache-2.0 (github.com/coollabsio/coolify); pgBackRest 2.60.0, MIT (pgbackrest.org); SOPS v3.13.3, MPL-2.0, e age v1.3.2, BSD-3 (GitHub); Metabase v0.64.3, AGPL fora de `enterprise/` ; Uptime Kuma 2.5.8, MIT; Redis 8 com opção AGPLv3 (redis.io/legal/licenses).
- **Chatwoot:** requisitos (PostgreSQL com pgvector, Redis 7+, mínimo de 4 vCPU e 4 GB) em developers.chatwoot.com/self-hosted/deployment/requirements; canal API e URL de callback em chatwoot.com/hc/user-guide (how-to-create-an-api-channel-inbox); Dashboard Apps em chatwoot.com/hc/user-guide (how-to-use-dashboard-apps); Agent Bots em chatwoot.com/hc/user-guide (how-to-use-agent-bots).
- **AWS (lista, São Paulo):** Lightsail em aws.amazon.com/lightsail/pricing e na Price List API (sa-east-1, publicação de 15/09/2026); RDS for PostgreSQL e S3 na Price List API (sa-east-1, publicações de 29/10 e 15/10/2026).
- **Alternativas:** Hostinger VPS em hostinger.com/br/servidor-vps e lista de data centers no suporte da Hostinger; Supabase em supabase.com/pricing e docs de regiões e de PITR.
- **Cloudflare:** plano Free (cloudflare.com/plans/free); DDoS (developers.cloudflare.com/ddos-protection); regras gerenciadas do WAF (developers.cloudflare.com/waf/managed-rules); Zero Trust Free até 50 usuários (cloudflare.com/plans/zero-trust-services); Tunnel gratuito para clientes Cloudflare One (blog.cloudflare.com/tunnel-hostname-routing, 18/09/2025); termos sobre vídeo nos planos sem serviço pago (FAQ do Cloudflare Tunnel).
- **Meta:** preços do WhatsApp, faixa grátis de serviço, janela de anúncio e cobrança em reais (developers.facebook.com/documentation/business-messaging/whatsapp/pricing, vigentes em 01/10/2026); Graph API v26.0 (developers.facebook.com/docs/graph-api/changelog); webhooks, assinatura e reenvio por 7 dias, Termos §4.7 e Business Tools §1.h (pesquisa de 28/10/2026).
- **Observabilidade:** Grafana Cloud Free (grafana.com/pricing); Sentry Developer (sentry.io/pricing).
- **Anthropic:** preços, cache e Batch (platform.claude.com/docs/en/about-claude/pricing); residência de dados, só `us` e `global` (platform.claude.com/docs/en/manage-claude/data-residency); retenção zero por acordo (platform.claude.com/docs/en/manage-

claude/api-and-data-retention).

- **Normas:** LGPD (Lei 13.709/2018), arts. 7º, 11, 18, 19, 33, 46 e 48; Resolução CD/ANPD nº 15/2024 (comunicação de incidente); Resolução CD/ANPD nº 19/2024 (transferência internacional e cláusulas-padrão).